

Plateforme LMS Hi! PARIS

Cahier des Charges Technique & Fonctionnel

Développement en propre · Studio de création IA · Conformité RGPD

Version 1.0 — Juin 2026

Hi! PARIS

Développement Interne

RGPD Natif

LLM Studio

Résumé Exécutif

Ce document constitue le cahier des charges complet de la plateforme LMS Hi! PARIS, développée entièrement en interne. Il couvre l'ensemble des besoins fonctionnels issus du kickoff, les spécifications RGPD à intégrer nativement dès la conception, ainsi que les modules du **Studio de création IA** permettant de générer automatiquement des quiz (depuis Excel) et des cours complets (depuis vidéos et slides) grâce à un LLM.

Paramètre	Valeur
Porteur du projet	Hi! PARIS (HEC Paris + École Polytechnique)
Mode de développement	Développement 100% interne, stack à définir
Périmètre v1	LMS core + RGPD + Studio IA (Excel→Quiz, Video+Slides→Cours)
Contrainte critique	Hébergement UE, conformité RGPD dès le day 1
Audience cible	Étudiants, Enseignants, Chercheurs, Admins Hi! PARIS

Table des Matières

1. Contexte & Vision

2. Architecture Fonctionnelle (Work Packages)

- WP1 — Gouvernance
- WP2 — Spécifications Techniques
- WP3 — Connexion & Gestion des Utilisateurs
- WP4 — Parcours Apprenant
- WP5 — Cours, MOOC & Certificats
- WP6 — Lecteur Vidéo
- WP7 — Applications & Outils
- WP8 — Média & Branding
- WP9 — Dashboard & Tracking

3. Studio de Création IA (MODULE CLÉ)

- Excel → Quiz
- Vidéo + Slides → Cours Complet

4. Conformité RGPD

- Principes fondateurs
- Données collectées & bases légales
- Droits des utilisateurs
- Sécurité technique
- Checklist développeur

5. Exigences Techniques Transverses

6. Plan de Développement par Étapes (Claude Code)

7. Glossaire

Contexte & Vision

Hi! PARIS est un centre interdisciplinaire dédié à l'IA et à la data, porté par HEC Paris et l'Institut Polytechnique de Paris. La plateforme LMS vise à centraliser l'ensemble des ressources pédagogiques de l'écosystème : cours, MOOC, certifications, vidéos, applications interactives et contenus éditoriaux.

Problèmes adressés par rapport à Moodle

Problème	Solution apportée
Interface	Datée, peu intuitive, courbe d'apprentissage élevée → UX moderne responsive
Performance	Lenteur sous charge → architecture scalable cloud-native
Engagement	Pas de gamification native → badges, points, parcours débloquables
Analytics	Reporting basique → dashboard temps-réel, alertes, export BI
Création contenu	Manuelle et fastidieuse → Studio IA (Excel→Quiz, Slides→Cours)
RGPD	Gestion parcellaire → conformité native dès la conception

Architecture Fonctionnelle — Work Packages

WP1 — Gouvernance

- Cartographie des parties prenantes (Hi! PARIS, académiques, tech, légales)
- Validation de la vision avec la direction — critères de succès v1
- Benchmark concurrentiel (Moodle, Coursera, 360Learning)
- Cadre du MVP : modules prioritaires, périmètre minimal viable
- Matrice de décision et comité de pilotage

WP2 — Spécifications Techniques

- Choix de la stack : langage, framework (React/Next.js + Node.js / Python recommandé)
- Sélection du provider cloud hébergé en UE (OVH, Scaleway, Clever Cloud...)
- Définition de l'architecture : microservices ou monolithe modulaire
- CI/CD pipeline, gestion des secrets, logs centralisés
- Négociation tarifaire via partenariats institutionnels (AWS, GCP, Azure)

WP3 — Connexion & Gestion des Utilisateurs

- Trois profils : Apprenant / Enseignant (super-user) / Admin Hi! PARIS
- Matrice des droits et permissions par profil
- Authentification : Token email (v0), Renater/SSO SAML 2.0 (v1)
- Import massif d'étudiants depuis Excel (.xlsx)
- Sécurisation BDD : chiffrement at-rest et in-transit
- RGPD : consentement, gestion des cookies, droit à l'oubli (cf. Section 4)

WP4 — Parcours Apprenant

- Parcours de connexion : UX flow, design, implémentation
- Parcours d'accès à un cours / vidéo / app
- Parcours certification : jalons, progression, validation finale
- Cycle systématique : Définition → UX/Maquette → Développement → Test → Mise en prod

WP5 — Cours, MOOC & Certificats

- Définitions distinctes : Cours (unité) / MOOC (parcours) / Certificat (validation)
- Benchmark des plateformes existantes pour bonnes pratiques
- Builder MOOC : besoins → construction → production → review
- Builder Certificat : démarrage décalé de 2 sprints après MOOC
- Support formats : vidéo, PDF, Markdown, SCORM, xAPI
- Studio IA intégré (voir Section 3 — MODULE CLÉ)

WP6 — Lecteur Vidéo

- Définition des métriques : temps de visionnage, taux de complétion, replays
- Hébergement : CDN externe (Vimeo, Mux) ou self-hosted (PeerTube)
- Espace de discussion intégré au lecteur (commentaires horodatés)
- Catalogue avec moteur de recherche, tags, recommandations
- Objectif catalogue v1 : volume minimal à définir avec l'équipe

WP7 — Applications & Outils

- Catalogue d'apps pédagogiques interactives (Python, TypeScript, JS)
- Specs d'intégration : apps existantes reliées via API GitHub → déploiement auto
- Sandboxing des apps pour isolation et sécurité
- Critères de qualité pédagogique pour validation avant publication
- Activités spécifiques : Hackathons, Neuripp, Data Boot Camp

WP8 — Média & Branding

- Charte graphique Hi! PARIS déclinée sur tous les modules
- Logo, couleurs, typographies standards
- Inside Insight : espace éditorial (articles, insights), builder dédié
- Gestion des droits d'auteur des contenus publiés

WP9 — Dashboard & Tracking

- KPIs plateforme : engagement, progression, temps passé, taux de complétion
- Dashboard accessible à l'équipe projet et aux enseignants
- Fiches élèves individuelles avec historique de progression
- Alertes automatiques sur apprenants en difficulté
- Builder Inside Insight avec tracking intégré
- Export données : CSV, Excel, connecteurs BI (Power BI, Metabase)
- Conformité RGPD sur toutes les données de tracking (cf. Section 4)

Studio de Création IA — MODULE CLÉ

Le Studio est un module différenciant de la plateforme. Il permet aux enseignants et contributeurs de générer automatiquement des contenus pédagogiques structurés à partir de fichiers existants, via un LLM orchestré. Deux pipelines sont prévus.

Pipeline 1 — Excel → Quiz

Étape	Description	Tech suggérée
1. Upload	L'enseignant uploade un fichier Excel (.xlsx) contenant des données brutes (QCM, paires question/réponse, ou données à analyser)	<i>multer / S3</i>
2. Parsing	Extraction et structuration des données : colonnes, types de données, valeurs	<i>SheetJS / openpyxl</i>
3. Prompt LLM	Génération d'un prompt contextualisé envoyé au LLM (Claude API) : type de quiz, niveau, nombre de questions, langue	<i>Anthropic SDK</i>
4. Génération	Le LLM retourne un JSON structuré : questions, options, bonne réponse, explication, niveau de difficulté	<i>claude-sonnet</i>
5. Preview & Edit	Interface de prévisualisation du quiz généré, avec édition inline avant publication	<i>React</i>
6. Publication	Sauvegarde en BDD et rattachement à un cours ou module	<i>PostgreSQL</i>

Format JSON attendu en sortie du LLM :

```
{ "quiz_title": "Introduction au Machine Learning", "difficulty": "intermédiaire",
"questions": [ { "id": 1, "question": "Qu'est-ce que la régression logistique ?",
"options": ["A. Un algorithme de clustering", "B. Un algorithme de classification supervisée", "C. Une méthode de réduction de dimension", "D. Un réseau de neurones"], "correct": "B", "explanation": "La régression logistique prédit une probabilité d'appartenance...", "difficulty": "facile", "source_row": 3 } ] }
```

Pipeline 2 — Vidéo + Slides → Cours Complet

Ce pipeline est plus complexe : il combine plusieurs sources d'entrée pour produire un cours structuré en Markdown avec tous ses composants pédagogiques.

1	Upload multi-sources	L'enseignant uploade une vidéo (MP4/YouTube URL) ET/OU un fichier de slides (PPTX, PDF)	<i>multer, yt-dlp</i>
---	-----------------------------	---	-----------------------

2	Transcription vidéo	Extraction de l'audio + transcription automatique via Whisper API ou équivalent	OpenAI Whisper / AssemblyAI
3	Extraction slides	Parsing du PPTX/PDF : extraction du texte par slide, ordre, titres, notes	python-pptx / pdfplumber
4	Alignement temporel	Matching automatique entre les slides et les segments de transcription	LLM / heuristiques
5	Construction du prompt	Assemblage d'un prompt structuré : transcription + contenu slides + instructions de structuration pédagogique	Anthropic SDK
6	Génération LLM	Le LLM génère un cours complet en Markdown : introduction, sections, résumés, quiz intégrés, bibliographie	claude-sonnet
7	Preview & Édition	Interface d'édition rich-text du cours généré avec prévisualisation side-by-side	React + MDX
8	Publication	Versioning du cours, publication sur la plateforme, notification des apprenants	PostgreSQL + S3

Structure Markdown générée par le LLM :

```
# [Titre du Cours] ## Objectifs pédagogiques - Comprendre... - Savoir appliquer... - Être capable de... ## Section 1 : [Titre issu de la slide 1] [Contenu synthétisé depuis transcription + slide] > ■ Point clé : ... ## Section 2 : ... ## Quiz de validation Question 1 : ... - [ ] Option A - [x] Option B (correct) - [ ] Option C ## Résumé ... ## Ressources complémentaires - [Lien 1] - Bibliographie générée
```

Conformité RGPD — Spécifications Natives

■ RGPD CRITIQUE : La conformité RGPD n'est pas une feature optionnelle. Elle doit être intégrée dès la conception (Privacy by Design). Toute collecte de donnée doit avoir une base légale documentée AVANT le développement.

4.1 Principes Fondateurs (Privacy by Design)

Principe	Implication technique
Minimisation	Ne collecter QUE les données strictement nécessaires à la finalité déclarée
Finalité	Chaque donnée a une finalité explicite documentée et ne peut être réutilisée autrement
Durée de conservation	Définir et implémenter des durées maximales (purge automatique)
Privacy by Default	Les options les plus protectrices doivent être activées par défaut
Transparence	L'utilisateur doit savoir exactement quelles données sont collectées et pourquoi
Intégrité & Confidentialité	Chiffrement, contrôle d'accès, audit logs obligatoires

4.2 Données Collectées & Bases Légales

Donnée	Base légale	Durée conservation	Consentement requis
Nom, prénom, email	Exécution du contrat (accès plateforme)	Durée du compte + 1 an	Non
Mot de passe	Exécution du contrat	Hashé (bcrypt/argon2), jamais en clair	Non
Progression dans les cours	Intérêt légitime pédagogique	Durée de scolarité + 1 an	Non
Temps de visionnage vidéo	Intérêt légitime (analytics)	6 mois glissants	Oui (opt-in)
Résultats aux quiz	Exécution du contrat	Durée de scolarité + 3 ans	Non
Logs de connexion	Obligation légale / sécurité	12 mois	Non
Cookies analytics	Consentement	13 mois max	Oui (opt-in)

Données de tracking comportemental	Consentement	6 mois max	Oui (opt-in)
------------------------------------	--------------	------------	--------------

4.3 Droits des Utilisateurs — Implémentation Obligatoire

Droit d'accès (Art. 15)	Endpoint API : GET /api/user/data — export JSON/CSV de toutes les données de l'utilisateur
Droit de rectification (Art. 16)	Interface de profil éditable + log d'audit des modifications
Droit à l'effacement (Art. 17)	Endpoint : DELETE /api/user/me — anonymisation + suppression dans les 30 jours, cascade sur toutes les tables
Droit à la portabilité (Art. 20)	Export standardisé : JSON conforme, incluant progression, résultats, certificats
Droit d'opposition (Art. 21)	Toggle granulaire dans les paramètres : analytics, emails, tracking comportemental
Consentement cookies	Banner RGPD au premier accès, granulaire par catégorie (nécessaires / analytics / marketing)

4.4 Sécurité Technique — Obligations

Domaine	Exigence
Mots de passe	Bcrypt ou Argon2id, coût adapté, jamais stocké en clair, reset sécurisé par token signé
Transport	HTTPS obligatoire (TLS 1.2+), HSTS, redirection HTTP→HTTPS
BDD	Chiffrement at-rest, accès restreint par service account, pas de credentials hardcodés
Tokens JWT	Expiration courte (15min access / 7j refresh), rotation des refresh tokens
Logs	Audit log immuable pour accès données sensibles, sans logger les données personnelles elles-mêmes
Upload fichiers	Validation type MIME côté serveur, scan antivirus, stockage isolé (S3 privé)
SQL Injection	ORM paramétré obligatoire (Prisma, SQLAlchemy), aucune concaténation de requête
XSS/CSRF	Sanitisation systématique des inputs, tokens CSRF, Content-Security-Policy header
Dépendances	Audit npm/pip régulier (npm audit, Dependabot), pas de packages abandonnés
Hébergement	Datacenter UE uniquement, DPA (Data Processing Agreement) signé avec chaque provider

4.5 Checklist Développeur RGPD

- Politique de confidentialité rédigée et accessible depuis toutes les pages
- Conditions d'utilisation et mentions légales publiées
- Bannière cookies RGPD-conforme (opt-in, granulaire, mémorisée)
- Formulaire de demande d'exercice des droits (accès, effacement, portabilité)
- Délai de réponse défini et respecté : 30 jours maximum
- Registre des traitements maintenu et accessible au DPO
- Durées de conservation implémentées avec jobs de purge automatique
- Tous les providers tiers ont signé un DPA (hébergeur, CDN, analytics)
- PIA (Privacy Impact Assessment) réalisé si traitement à risque
- Procédure de notification de violation de données (72h à la CNIL)
- Aucune donnée personnelle dans les logs applicatifs
- Anonymisation des données avant export analytics ou tests

Exigences Techniques Transverses

Critère	Exigence	Priorité
Performance	LCP < 2.5s, TTI < 3.5s, Lighthouse score ≥ 85	Haute
Disponibilité	SLA 99.5% minimum, maintenance planifiée hors heures de cours	Haute
Scalabilité	Supporter 500 utilisateurs simultanés en v1, 5000 en v2	Haute
Accessibilité	WCAG 2.1 AA, support lecteur d'écran, navigation clavier	Moyenne
Internationalisation	Français (obligatoire), Anglais (v1), autres langues (v2)	Haute
Mobile	Responsive obligatoire, PWA en v2	Haute
API	REST API versionnée (/api/v1/...), documentation OpenAPI/Swagger	Haute
Tests	Couverture ≥ 80% (unit + integration), E2E sur parcours critiques	Moyenne
Monitoring	Alerting sur erreurs 5xx, latence, uptime (Sentry, Datadog ou équivalent)	Haute

Stack Technique Recommandée

Couche	Technologie
Frontend	Next.js 14+ (App Router), TypeScript, Tailwind CSS, Shadcn/UI
Backend	Node.js + Express ou FastAPI (Python) selon affinité équipe
Base de données	PostgreSQL (principal) + Redis (sessions/cache)
ORM	Prisma (Node) ou SQLAlchemy (Python)
Stockage fichiers	S3-compatible (Scaleway Object Storage ou MinIO self-hosted)
Auth	NextAuth.js ou custom JWT + Renater SAML 2.0 (v1)
LLM (Studio IA)	Anthropic Claude API (claude-sonnet-4-20250514)
Transcription	Whisper API (OpenAI) ou AssemblyAI
Email	Resend ou SendGrid
CI/CD	GitHub Actions → Docker → Registry → Déploiement auto
Monitoring	Sentry (erreurs) + Grafana/Prometheus (métriques)

Plan de Développement — Guide pour Claude Code

Ce plan est structuré pour être utilisé directement avec Claude Code. Chaque étape est autonome, testable et livrable. Respecter l'ordre : chaque étape dépend des fondations posées par les précédentes.

Phase 0 — Fondations (Semaine 1-2)

- 1 Initialiser le projet Next.js + TypeScript avec structure de dossiers
- 2 Configurer PostgreSQL + Prisma, créer le schéma initial (User, Course, Module, Quiz)
- 3 Mettre en place CI/CD GitHub Actions basique (lint, test, build)
- 4 Configurer les variables d'environnement et la gestion des secrets
- 5 Déployer un environnement de staging sur le provider UE choisi

Phase 1 — Auth & RGPD Core (Semaine 3-4)

- 1 Système d'authentification : inscription, connexion, token email
- 2 Middleware de session sécurisé (JWT, refresh tokens)
- 3 Bannière RGPD + gestion des préférences cookies (stockage BDD, pas localStorage)
- 4 Endpoints RGPD : GET /api/user/data, DELETE /api/user/me, GET /api/user/export
- 5 Page Politique de confidentialité + CGU
- 6 Matrice de rôles (Apprenant / Enseignant / Admin) avec middleware d'autorisation
- 7 Import massif utilisateurs via Excel (parsing + validation + création batch)

Phase 2 — Cours & Contenu (Semaine 5-7)

- 1 Modèle de données : Course → Module → Lesson → Quiz
- 2 CRUD cours pour les enseignants (interface admin)
- 3 Lecteur de contenu pour les apprenants (Markdown, vidéo embed, PDF)
- 4 Système de progression : tracking lecture, marquage 'complété'
- 5 Lecteur vidéo avec métriques (temps de visionnage, événements)
- 6 Espace commentaires horodatés sur les vidéos

Phase 3 — Studio IA : Excel → Quiz (Semaine 8-9)

- 1 Interface d'upload Excel avec validation du format
- 2 Parser SheetJS côté client ou openpyxl côté serveur
- 3 Intégration Anthropic Claude API : prompt engineering pour génération quiz
- 4 Parsing de la réponse JSON structurée du LLM
- 5 Interface de prévisualisation et d'édition du quiz généré
- 6 Sauvegarde et publication du quiz dans un cours
- 7 Gestion des erreurs LLM (retry, fallback, messages utilisateur)

Phase 4 — Studio IA : Vidéo+Slides → Cours (Semaine 10-12)

- 1 Upload vidéo ou saisie URL YouTube/Vimeo
- 2 Intégration Whisper API pour transcription automatique
- 3 Upload PPTX/PDF + extraction texte (python-pptx / pdfplumber via API)
- 4 Alignement temporel transcription ↔ slides
- 5 Prompt LLM pour génération du cours Markdown complet
- 6 Interface d'édition rich-text (MDX Editor) avec preview side-by-side
- 7 Publication versionnée sur la plateforme

Phase 5 — MOOC, Parcours & Certifications (Semaine 13-15)

- 1 Modèle de données Parcours : assemblage de cours en séquence
- 2 Logique de déverrouillage conditionnel (prérequis, score minimum)
- 3 Génération automatique de certificats PDF (avec QR code de vérification)
- 4 Système de badges (gamification basique)
- 5 Tableau de bord apprenant : progression globale, badges, certificats

Phase 6 — Dashboard & Analytics (Semaine 16-17)

- 1 Dashboard enseignant : suivi cohorte, taux de complétion, alertes
- 2 Dashboard admin Hi! PARIS : KPIs globaux plateforme
- 3 Fiches élèves individuelles
- 4 Export CSV/Excel des données de suivi

- 5 Alertes automatiques sur apprenants en difficulté (seuil configurable)

Phase 7 — Applications & Finalisation (Semaine 18-20)

- 1 Catalogue d'applications pédagogiques avec intégration GitHub API
- 2 Module Inside Insight (articles éditoriaux)
- 3 Optimisations performance (lazy loading, cache, CDN)
- 4 Audit sécurité et RGPD complet avant mise en production
- 5 Tests E2E sur tous les parcours critiques
- 6 Documentation technique complète
- 7 Formation équipe et mise en production v1

Glossaire

Terme	Définition
RGPD	Règlement Général sur la Protection des Données (EU 2016/679)
LMS	Learning Management System — plateforme de gestion de l'apprentissage
MOOC	Massive Open Online Course — parcours de cours en ligne structuré
xAPI / Tin Can	Standard de tracking des activités d'apprentissage (successeur SCORM)
SCORM	Sharable Content Object Reference Model — standard d'interopérabilité e-learning
SSO	Single Sign-On — authentification unique multi-services
SAML 2.0	Security Assertion Markup Language — protocole SSO fédéré (utilisé par Renater)
Renater	Réseau national de télécommunications pour la technologie, l'enseignement et la recherche
DPO	Data Protection Officer — délégué à la protection des données
PIA	Privacy Impact Assessment — analyse d'impact relative à la protection des données
DPA	Data Processing Agreement — contrat de sous-traitance RGPD avec les providers
CDN	Content Delivery Network — réseau de distribution de contenu
LLM	Large Language Model — modèle de langage de grande taille (ex: Claude)
Studio IA	Module de la plateforme permettant la génération automatique de contenus via LLM
JWT	JSON Web Token — standard d'authentification stateless
ORM	Object-Relational Mapping — abstraction BDD (Prisma, SQLAlchemy)
CSP	Content Security Policy — header HTTP de protection contre XSS
KPI	Key Performance Indicator — indicateur clé de performance